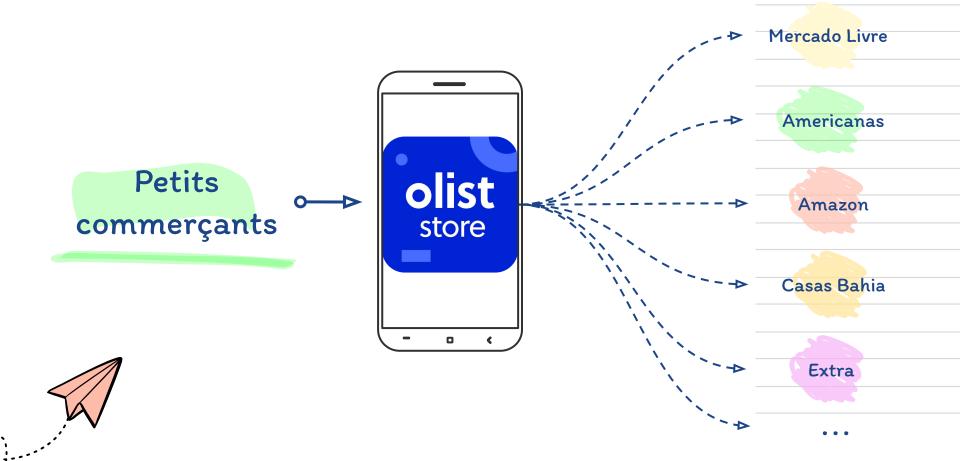


#### Marché e-commerce brésilien fractionné



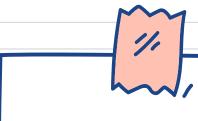
## Missions:





Segmentation utilisable par le marketing





Contrat de Maintenance













# Extraits de 9 tables SQL



#### Clients

Ligne = une commande

#### **Produits**

Ligne = un produit commandé





#### Paiement

Ligne = un moyen de paiement utilisé

#### **Avis**

Ligne = un commentaire





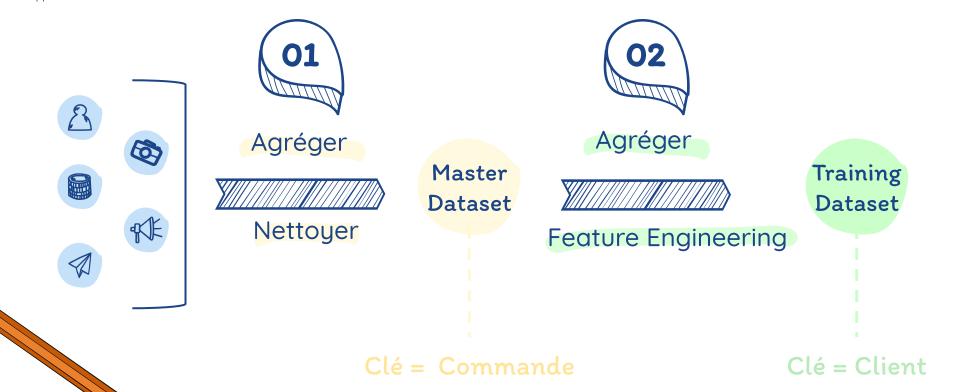
#### Commandes

Ligne = une commande



96\_096 clients

# Construction jeu de données





## Traitement des valeurs manquantes

O Note satisfaction client — → Moyenne

Nombre de produits

Montant commande

Coût moyen d'un produit

\*\*Conserve les outliers



#### 5 Features



Nombre de jours depuis la dernière commande

Fréquence

Nombre de commandes

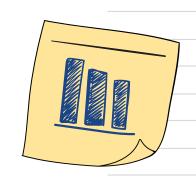
Montant

Montant total des achats



Nombre moyen de produits par commande



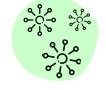




## Classification non supervisée = Clustering

#### 3 algorithmes d'apprentissage:







Classification ascendante hiérarchique

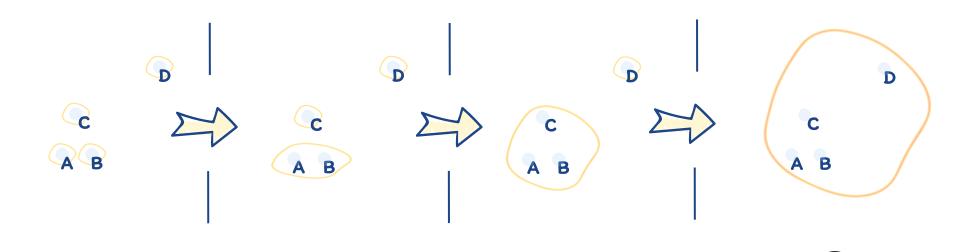
**KMeans** 

DBSCAN

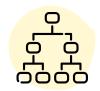


## Clustering Agglomératif



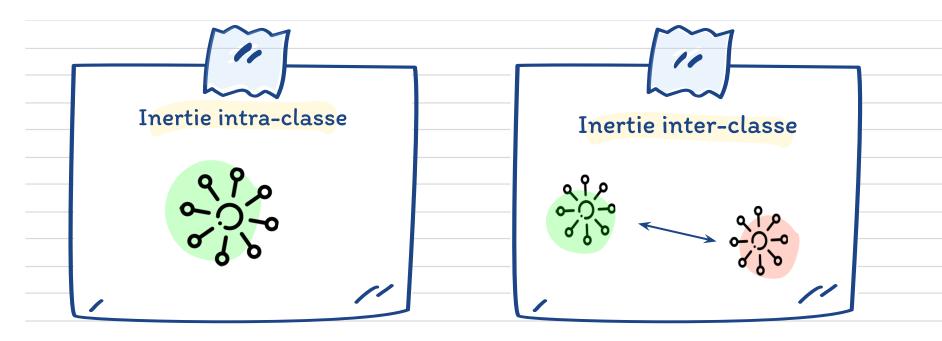


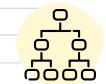




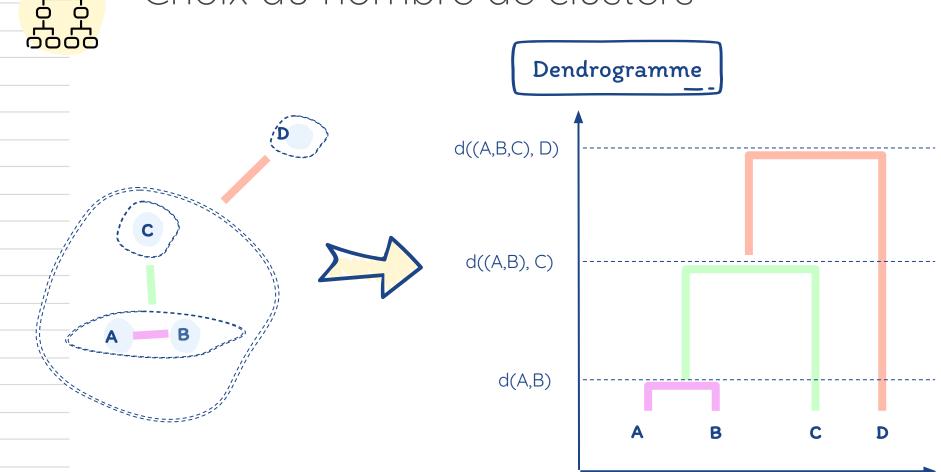
#### Méthode de Ward:

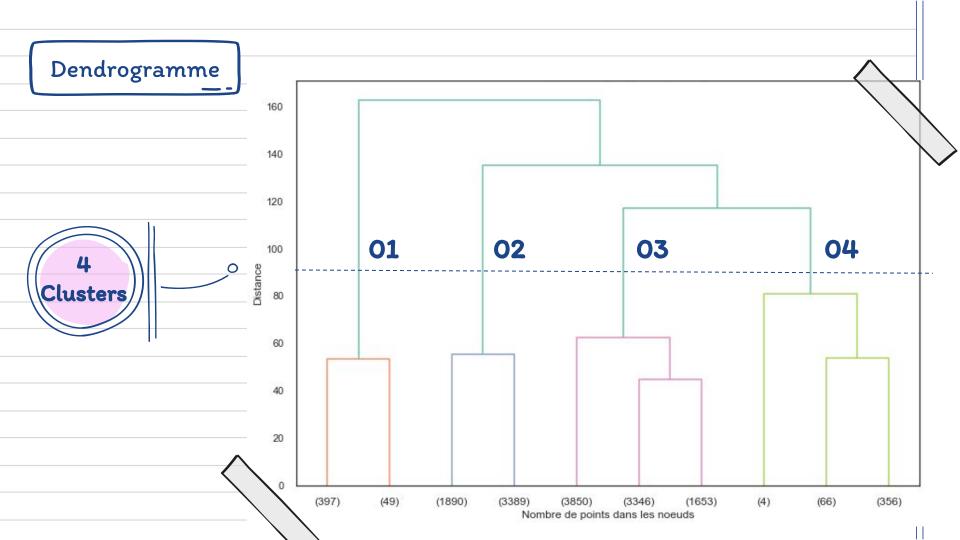
Agrège les clusters dont l'agrégation minimise l'augmentation de l'inertie intraclasse.





#### Choix du nombre de clusters

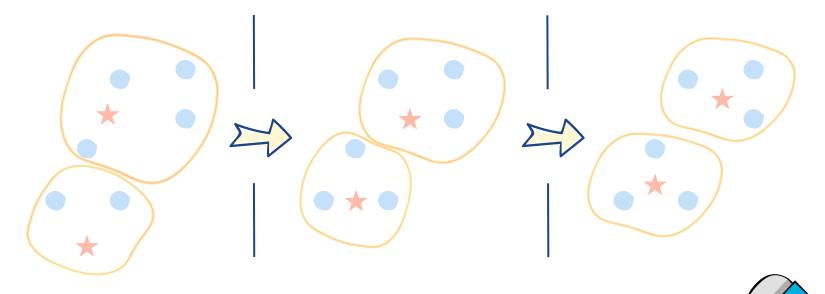






## K-Means







Centre de gravité du cluster



#### K-Means

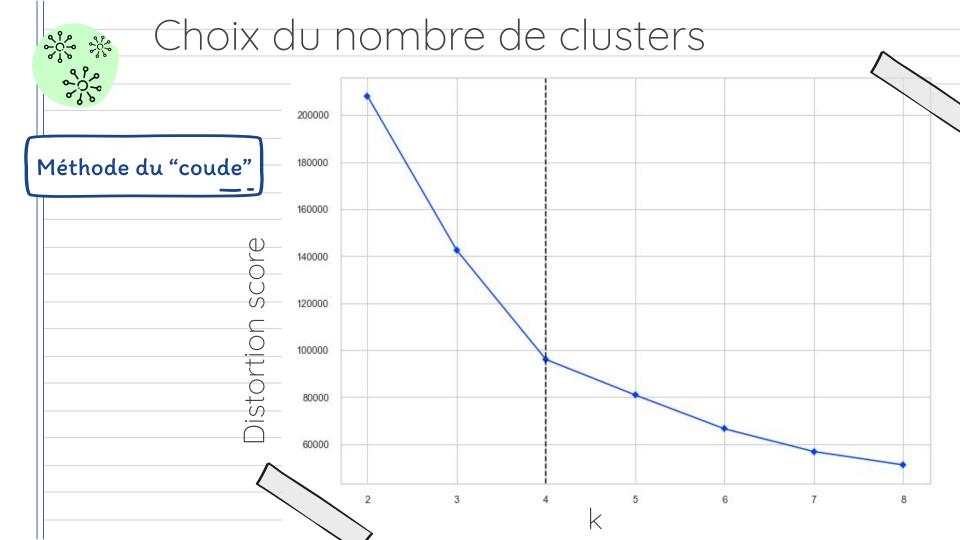
#### Limites

- Algorithme non-déterministe
- Minimum local

#### Solutions

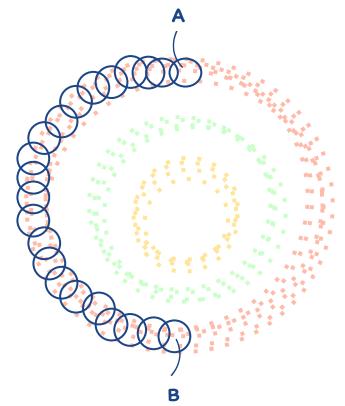
- Relancer + choisir le résultat qui minimise l'inertie intra-classe
- K-Means ++

\*\*par défaut dans sklearn





#### DBSCAN



Clusters = points atteignables par densité les uns depuis les autres

Epsilon voisinage





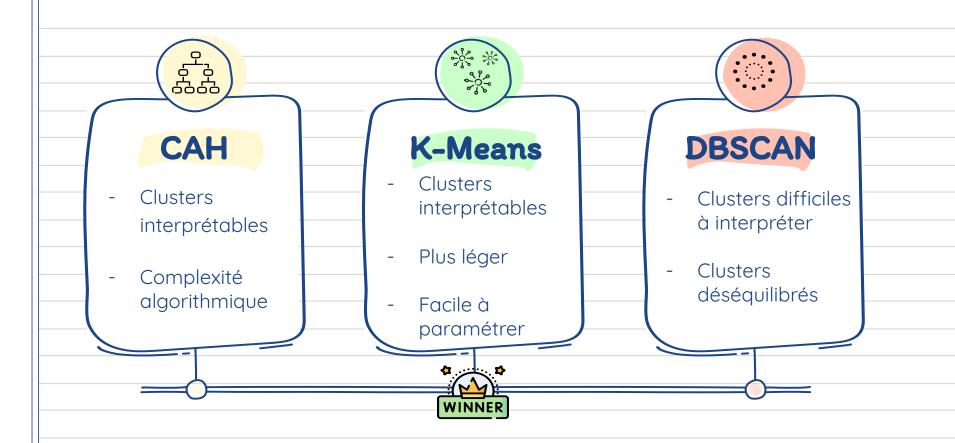
## Choix des hyperparamètres

Nombre de voisins minimum :

2 \* nombre de dimensions Distance moyenne de chaque observation à ses 6 voisins Epsilon voisinage: méthode du coude Distance moyenne aux 6 voisins

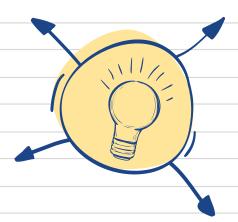
Observations

## Algorithme le plus adapté



### Evaluer la performance des modèles

- O Clusters vs connaissances du domaine : pairplot, boxplot, radarplot
- O Clusters équilibrés : diagramme circulaire
- Forme des clusters : coefficient de silhouette



#### Coefficient de silhouette



Évalue à quel point l'individu x appartient au "bon" cluster



Homogénéité : "x" proche des points du cluster auquel il appartient ?

$$a(x) = \frac{1}{|C_k| - 1} \sum_{u \in C_k, u \neq x} d(u, x)$$

Séparation: "x" loin des points des autres clusters?



$$b(x) = \min_{l \neq k} \frac{1}{|C_l|} \sum_{l \in C_l} d(u, x)$$

#### Coefficient de silhouette

Évalue à quel point l'individu x appartient au "bon" cluster



$$s(x) = \frac{1}{\max(a(x), b(x))}$$

## Comparaison modèles

	Nombre de Clusters	Coefficient de Silhouette	Répartition
RFM	4	0.489	40%   54%   3%   3%
RFM + Produits	5	0.442	39%   53%   3%   2%   2%
RFM + Note	5	0.418	33%   44%   17%   3%   2%
RFM + Note + Produits	5	0.368	33%   44%   17%   3%   3%

#### one time shoppers



#### new customers



#### dissatisfied customers



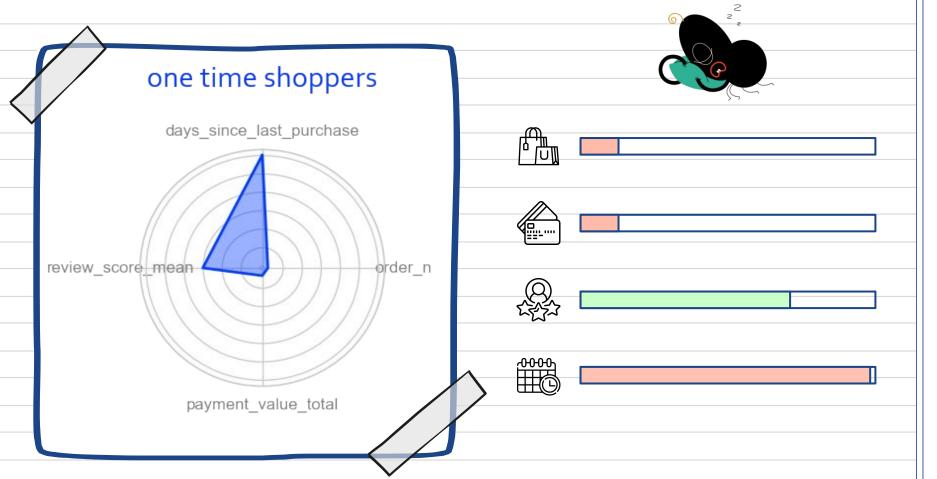
#### loyal customers

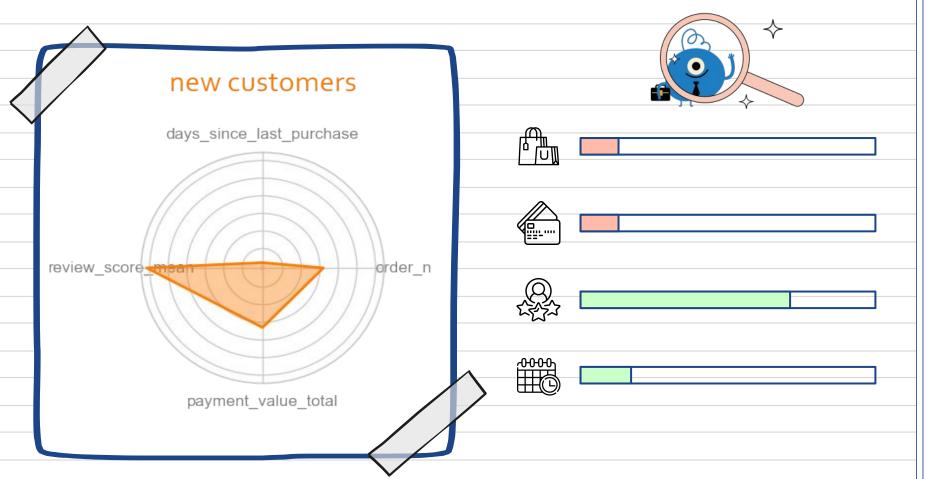


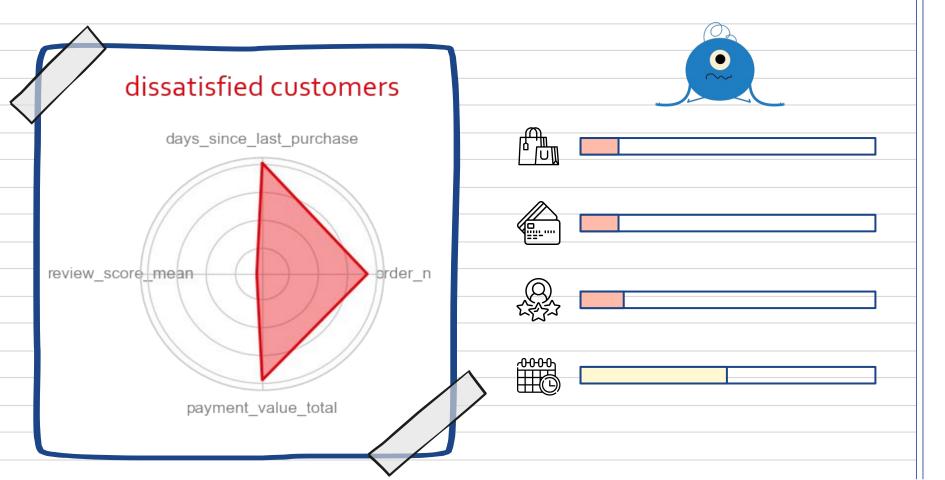


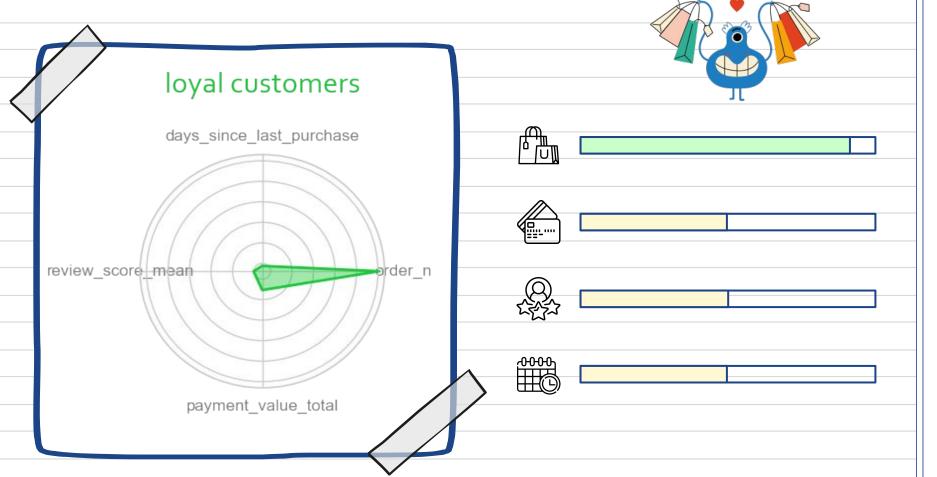
#### spendthrifts

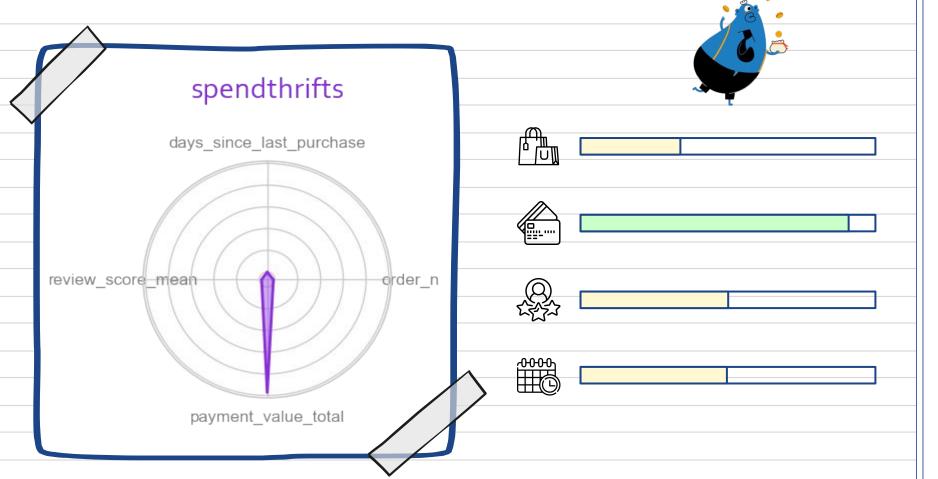




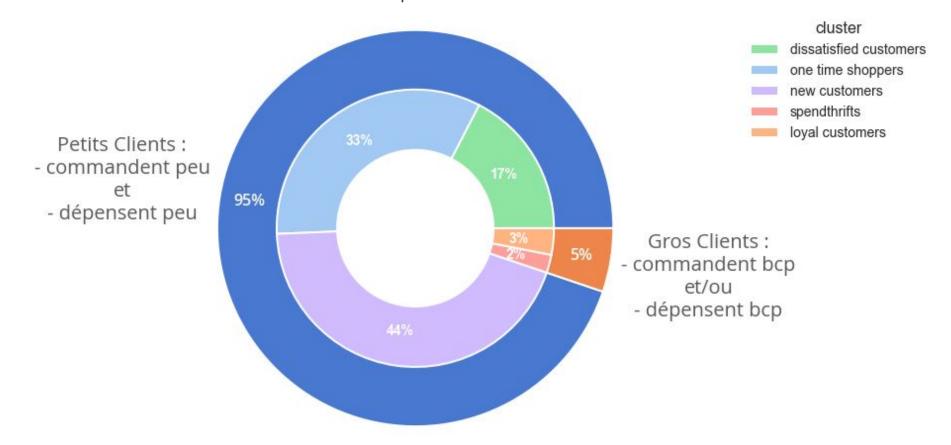






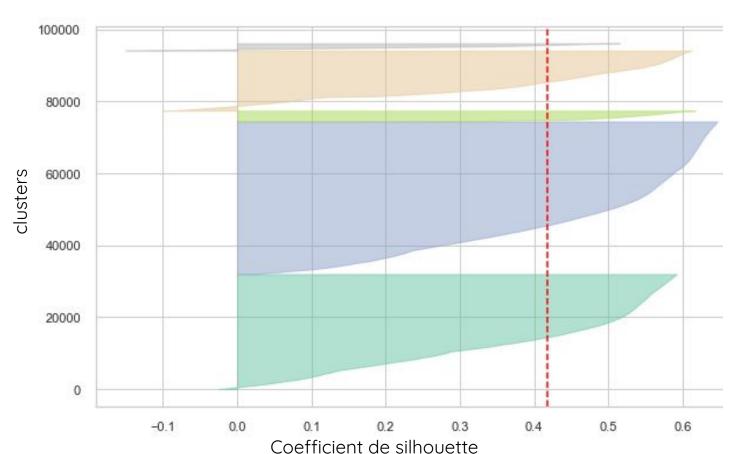


### Nombre d'individus par cluster



#### Coefficients de silhouette











## Indice de Rand ajusté

Évalue la concordance de deux partitions du jeu de données





$$ARI = \frac{RI - E(RI)}{\max(RI) - E(RI)}$$



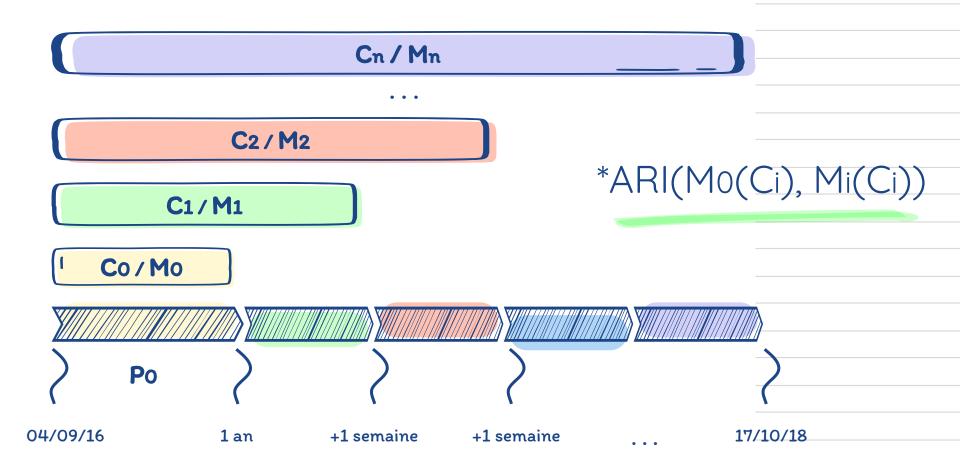


Clustering aléatoire

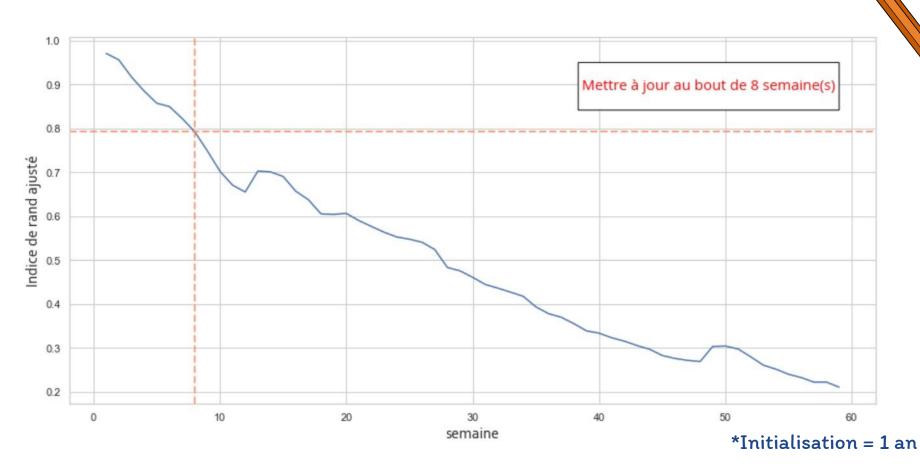
Clustering correspond exactement à la partition initiale

\*RI: indice de rand

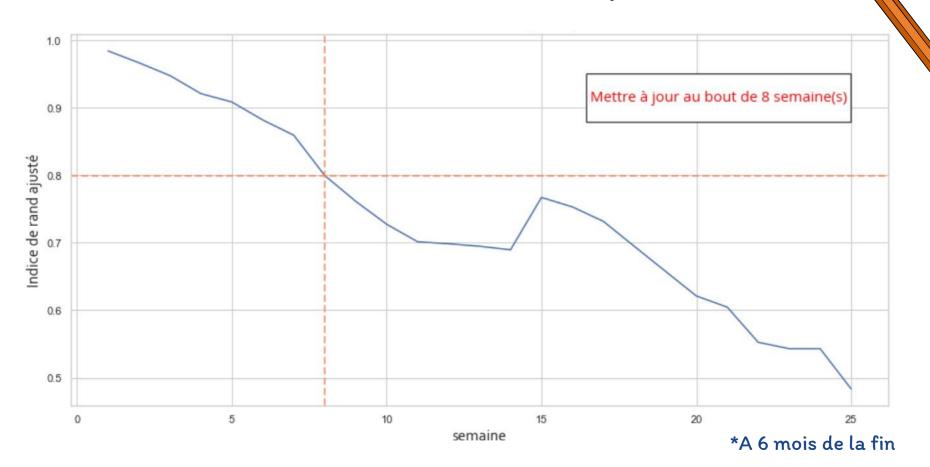
Fréquence de mise à jour du modèle:



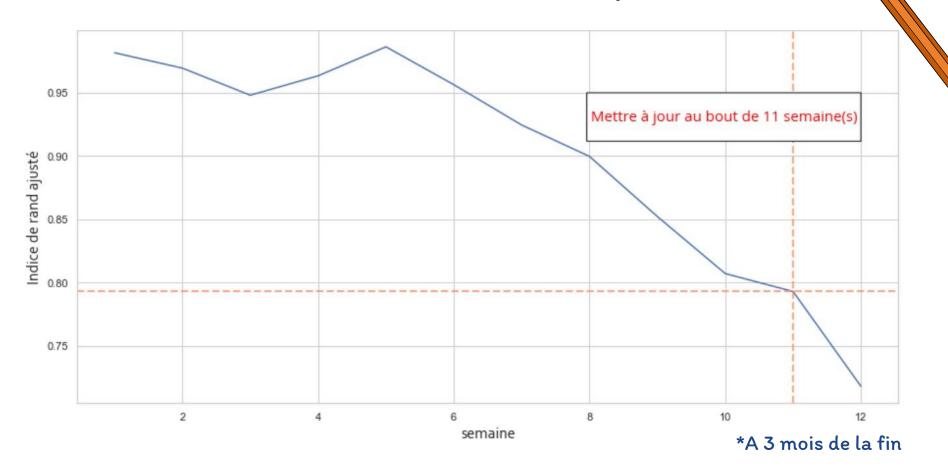
## Evolution de l'indice de rand ajusté :



### Evolution de l'indice de rand ajusté :



### Evolution de l'indice de rand ajusté :



# Conclusion:

- Algo d'apprentissage : KMeans
- Features : RFM + note moyenne
- Profils Clients: 5



Mise à jour : tous les 2 mois ou automatiser



#### Inertie:

Inertie interclasse =  $1/n * \Sigma n_c d(G_c, G)^2$ 

Inertie intra-classe =  $1/n * \Sigma \Sigma d(M_i, G_c)^2$ 

d : distance euclidienne

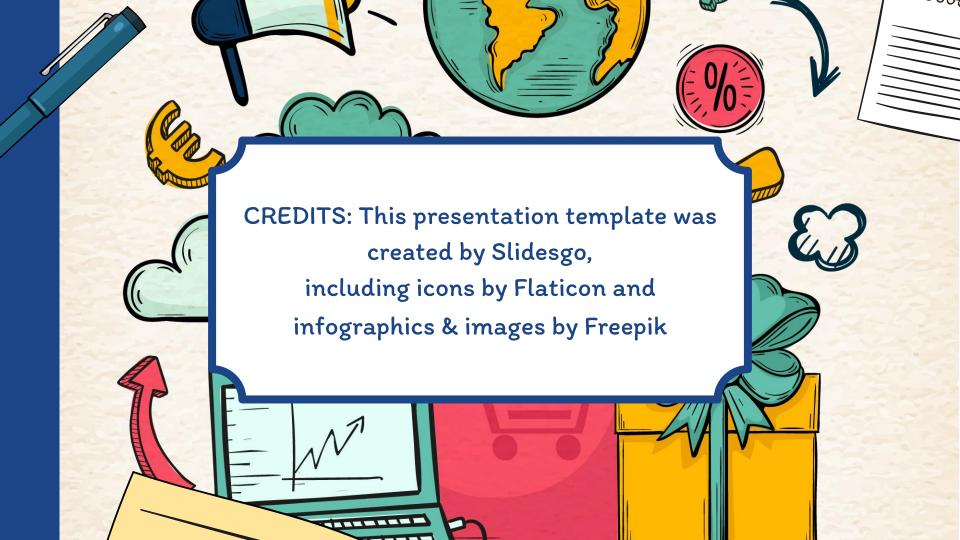
n : nombre d'individus dans le nuage

n<sub>c</sub>: nombre d'individus dans la classe "c"

G : centre de gravité du nuage d'individus

 $G_{\circ}$  : centre de gravité de la classe "c"

M: point correspondant à l'individu i



## **slides**go